

EFRI 模型推导

April 18, 2020

1 模型概述

EFRI 模型涉及大量标量、超参数、隐变量和可观测变量，所用符号及其含义如表 1所示。

各个超参数、隐变量和可观测变量之间的概率依赖关系如图 1所示。为了简化表示，图中变量没有加索引。需要注意的是， ξ 和 π 都服从狄利克雷分布，二者的超参数不同，分别为 (β_ξ) 和 (β_π) ，在这里都简写为 β 。 λ 、 ψ 、 c 和 h 的方差变量 σ^2 也是同理。

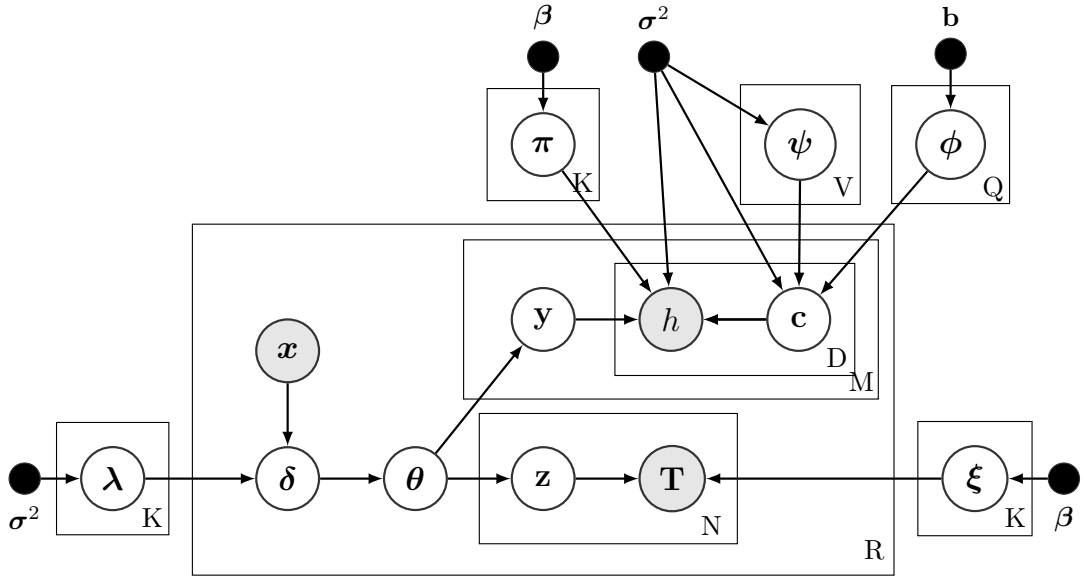


图 1: EFRI 的贝叶斯网络图

表 1: EFRI 符号表

变量种类	符号	含义
标量	R	区域的总个数。
	K	城市功能个数（聚类个数）。
	F	POI 兴趣点类型的总数。
	M	区域中评论的个数。
	N	区域中时间区间的个数。
	D	评论中包含的城市特征个数。
	V	城市特征的总个数。
	Q	城市活动的总个数。
	G	嵌入向量的维度。
	I	移动起止点统计量的取值区间个数。
超参数	σ^2	高斯分布的方差变量。
	β	狄利克雷分布的超参数。
	b	拉普拉斯分布的方差变量。
隐变量	θ_r	区域 r 的城市功能分布。
	ξ_k	主题 k 下，移动起止点向量的数值在 I 个区间的分布。
	π_k	第 k 个城市功能下各个城市活动的分布。
	ψ_v	城市特征 v 的嵌入向量。
	ϕ_q	城市活动 q 的嵌入向量。
	λ_k	城市功能 k 中各个不同兴趣点 POI 的权重。
	δ_r	原 POI 特征向量 \mathbf{x}_r 经过加权后的 POI 特征向量。
	$\mathbf{c}_{r,m,d}$	区域 r 内评论 m 中的第 d 个城市特征与各城市活动的相关性。
	$\mathbf{z}_{r,n}$	区域 r 内第 n 个时间区间所对应的功能分布。
	$\mathbf{y}_{r,m}$	区域 r 内评论 m 所对应的功能分布。
可观测变量	\mathbf{T}_r	区域 r 的移动起止点矩阵。
	\mathbf{x}_r	区域 r 的 POI 特征向量。
	$h(r, m, d)$	区域 r 内评论 m 中第 d 个词位置对应的函数值。

2 变分推断

在公式 1 中, L_p 表示 EFRI 模型的对数似然函数, L_1 表示评论文本数据的似然函数, L_2 表示移动起止点数据的似然函数。求解模型的目标是最大化如公式 1 所示的对数似然函数。

$$L_p = L_1 + L_2, \quad (1)$$

$$L_1 = \log[p(h|\boldsymbol{\lambda}, \boldsymbol{\delta}, \boldsymbol{\theta}, \boldsymbol{\pi}, \boldsymbol{\phi}, \boldsymbol{\psi}, \mathbf{y}, \mathbf{c}) \cdot p(\boldsymbol{\lambda}, \boldsymbol{\delta}, \boldsymbol{\theta}, \boldsymbol{\pi}, \boldsymbol{\phi}, \boldsymbol{\psi}, \mathbf{y}, \mathbf{c}|\boldsymbol{\sigma}^2, \boldsymbol{\beta}, \mathbf{b})],$$

$$L_2 = \log[p(\mathbf{T}|\boldsymbol{\lambda}, \boldsymbol{\delta}, \boldsymbol{\theta}, \boldsymbol{\xi}, \mathbf{z})p(\boldsymbol{\lambda}, \boldsymbol{\delta}, \boldsymbol{\theta}, \boldsymbol{\xi}, \mathbf{z}|\boldsymbol{\sigma}^2, \boldsymbol{\beta}, \mathbf{b})].$$

如图 1 所示, 变量间的依赖关系如下所示:

- $p(\boldsymbol{\lambda}_k) = \mathcal{N}(0, \sigma_\lambda^2 I)$, $\boldsymbol{\lambda}_k$ 表示功能 k 中各个不同兴趣点的权重, 由高斯分布生成。需要注意的是, 这里的 σ_λ 的下标 λ 不是索引, 是为了跟其它隐变量 $\boldsymbol{\psi}$ 、 c 等的参数有区分。
- $\delta_{r,k} = \frac{\exp\{\delta_{r,k}\}}{\sum_{k'} \exp\{\delta_{r,k'}\}} \frac{\exp\{\mathbf{x}_r^T \boldsymbol{\lambda}_k\}}{\sum_{k'} \exp\{\mathbf{x}_r^T \boldsymbol{\lambda}_{k'}\}}$, δ_r 表示原 POI 特征向量 \mathbf{x}_r 经过 $\boldsymbol{\lambda}_k$ 加权并规范化后的 POI 特征向量。
- $p(\boldsymbol{\theta}_r) = \text{Dir}(\boldsymbol{\delta}_r)$, $\boldsymbol{\theta}_r$ 表示区域 r 的主题分布, 服从参数为 $\boldsymbol{\delta}_r$ 的狄利克雷分布。
- $p(\mathbf{z}_{r,n}) = \text{Mult}(\boldsymbol{\theta}_r)$, $\mathbf{z}_{r,n}$ 表示区域 r 内第 n 个时间区间所对应的主题分布, 服从参数为 $\boldsymbol{\theta}_r$ 的多项式分布。
- $p(\boldsymbol{\xi}_k) = \text{Dir}(\boldsymbol{\beta}_\xi)$, $\boldsymbol{\xi}_k$ 表示主题 k 下, 移动轨迹向量的数值在 I 个区间的分布。服从参数为 $\boldsymbol{\beta}_\xi$ 的狄利克雷分布。需要注意的是, 这里的 $\boldsymbol{\beta}_\xi$ 是一个向量, 下标 ξ 不是索引, 是为了跟另一个隐变量 $\boldsymbol{\pi}$ 的参数有区分。
- $p(\mathbf{t}_{r,n}) = \text{Mult}(\boldsymbol{\xi}_{\mathbf{z}_{r,n}})$, $\mathbf{t}_{r,n}$ 表示输入的移动起止点特征矩阵 \mathbf{T}_r 的第 n 个向量。
- $p(\mathbf{y}_{r,m}) = \text{Mult}(\boldsymbol{\theta}_r)$, $\mathbf{y}_{r,m}$ 表示区域 r 内评论 m 所对应的主题分布, 服从参数为 $\boldsymbol{\theta}_r$ 的多项式分布。
- $p(\boldsymbol{\pi}_k) = \text{Dir}(\boldsymbol{\beta})$, $\boldsymbol{\pi}_k$ 表示第 k 个城市主题下各个城市功能的分布。

- $p(\psi_v) = \mathcal{N}(0, \sigma_\psi^2 I)$, ψ_v 表示第 v 个城市特征的词嵌入向量, 服从方差为 σ_ψ^2 的高斯分布。
- $p(\phi_q) = \mathcal{Laplace}(0, \mathbf{b})$, ϕ_q 表示第 q 个城市功能的词嵌入向量, 服从位置参数为 0、尺度参数为 \mathbf{b} 的拉普拉斯分布。
- $p(\mathbf{c}_{r,m,d}) = \mathcal{N}(\Phi \psi_{v(d)}^T, \sigma_c^2)$, $\mathbf{c}_{r,m,d}$ 表示在区域 r 内评论 m 中城市特征 d 与各个城市功能的相关性。
- $p(h) = \mathcal{N}(\pi_{y_{r,m}}^T \mathbf{c}_{r,m,d}, \sigma_w^2)$, 其中 h 表示区域 r 内评论 m 中第 d 个位置对应的可观测函数值 $h(r, m, d)$ 。

公式 1 涉及到隐变量的耦合, 难以直接求解。因此使用变分推断 (Variational Inference) EM 算法 [1, 2] 来求解参数。变分推断基于平均场理论 (Mean Field Assumption), 假设所有的隐变量都是通过各自的独立分布形成的。在 EFRI 中, 假设每个隐变量都各自服从对应的变分分布, 如图 2 所示。与 1 一样, 图 2 省略了变量索引。若一个隐变量只有一个变分分布的参数, 如 y , 则 \mathbf{y} 对应的变分参数用 \mathbf{y}' 的形式来表示。若一个隐变量服从的变分分布中有两个不同参数, 则用增加上标的形式来表示变分参数, 如 λ 的期望参数和方差参数分别表示为 $\lambda^{(\mu)}$ 和 $\lambda^{(\sigma^2)}$ 。

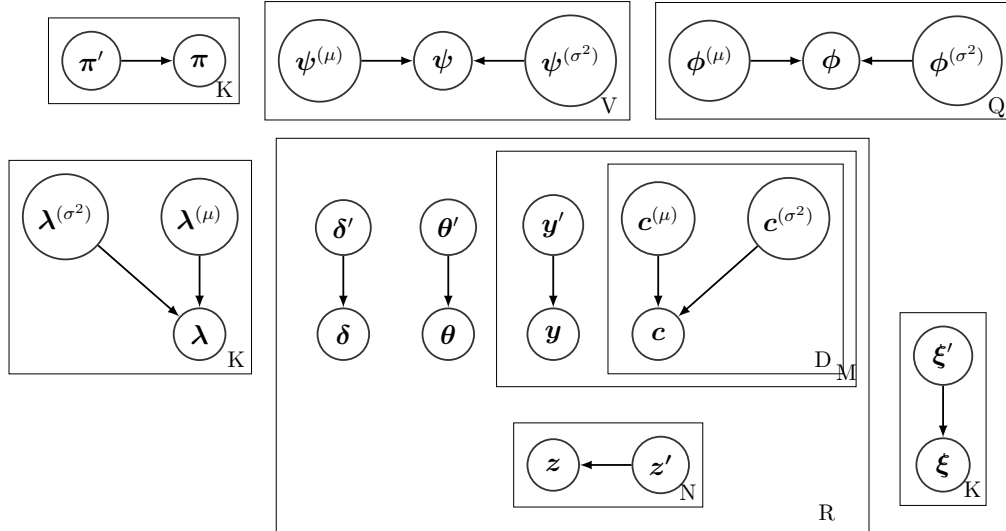


图 2: EFRI 的独立变分分布图

由图 2 可以得到隐变量的变分分布

$$q(\boldsymbol{\lambda}, \boldsymbol{\delta}, \boldsymbol{\theta}, \mathbf{z}, \boldsymbol{\xi}, \mathbf{y}, \boldsymbol{\pi}, \boldsymbol{\psi}, \boldsymbol{\phi}, \mathbf{c}) \quad (2)$$

$$= \prod_{k=1}^K q(\boldsymbol{\lambda}_k) q(\boldsymbol{\pi}_k) q(\boldsymbol{\xi}_k) \prod_{v=1}^V q(\boldsymbol{\psi}_v) \prod_{q=1}^Q q(\boldsymbol{\phi}_q) \prod_{r=1}^R \left[q(\boldsymbol{\delta}_r) q(\boldsymbol{\theta}_r) \prod_{n=1}^N q(\mathbf{z}_{r,n}) \prod_{m=1}^M \left(q(\mathbf{y}_{r,m}) \prod_{d=1}^D q(\mathbf{c}_{r,m,d}) \right) \right].$$

变分推断的目标是用 $q(\boldsymbol{\lambda}, \boldsymbol{\theta}, \mathbf{z}, \boldsymbol{\xi}, \mathbf{y}, \boldsymbol{\pi}, \boldsymbol{\psi}, \boldsymbol{\phi}, \mathbf{c})$ 来近似地估计对数似然函数 L_p ，希望这两个分布尽可能的相似，也就是希望这两个概率分布之间的 KL 距离 $KL(q||p)$ 尽可能小。模型的求解目标变为计算合适的隐变量的值，使对应的 $q(\boldsymbol{\lambda}, \boldsymbol{\theta}, \mathbf{z}, \boldsymbol{\xi}, \mathbf{y}, \boldsymbol{\pi}, \boldsymbol{\psi}, \boldsymbol{\phi}, \mathbf{c})$ 能尽可能近似对数似然函数 L_p ，进而使用 EM 算法迭代。

根据 Bishop [3] 对变分推断的介绍，模型的对数似然函数可以表示为：

$$L_p = \text{ELBO} + KL(q||p), \quad (3)$$

其中 ELBO(Evidence Lower **BO**und) 是模型的最大化证据下界，表示为：

$$\text{ELBO} = \mathbb{E}_q[L_p] - \mathbb{E}_q[q(\boldsymbol{\lambda}, \boldsymbol{\theta}, \mathbf{z}, \boldsymbol{\xi}, \mathbf{y}, \boldsymbol{\pi}, \boldsymbol{\psi}, \boldsymbol{\phi}, \mathbf{c})]. \quad (4)$$

由于对数似然部分 L_p 与 KL 散度无关，可以看做常量，因此模型的求解目标从最小化 KL 散度等价转换为求 ELBO 最大值。

3 算法步骤

Algorithm Steps 根据变分推断求解 EFRI 的步骤如下：

1. 初始化所有的变分参数和超参数。
2. 进行 EFRI 的 E 步骤循环迭代。

(a) 对于 $\forall k \in \{1, 2, \dots, K\}, \forall i \in \{1, 2, \dots, I\}$ ，更新 $\xi'_{k,i}$ ：

$$\xi'_{k,i} = (\beta_\xi)_i + \sum_{r=1}^R \sum_{n=1}^N z'_{r,n,k} t_{r,n,i}.$$

(b) 对于 $\forall k \in \{1, 2, \dots, K\}, \forall q \in \{1, 2, \dots, Q\}$, 更新 $\pi'_{k,q}$:

$$\pi'_{k,q} = (\beta_\pi)_q + \sum_{r=1}^R \sum_{m=1}^M y'_{r,m,k} \sum_{d=1}^D \sum_{v=1}^V h(r, m, d)^v.$$

其中 $h(r, m, d)^v = h(r, m, d)$ 当且仅当区域 r 内评论 m 中第 d 个城市特征是 v 时成立, 否则 $h(r, m, d)^v = 0$ 。

(c) 对于 $\forall q \in \{1, 2, \dots, Q\}, \forall g \in \{1, 2, \dots, G\}$, 更新 $\phi_{q,g}^{(\mu)}$:

$$\phi_{q,g}^{(\mu)} = \frac{\sum_{r=1}^R \sum_{m=1}^M \sum_{d=1}^D \sum_{k=1}^K \sum_{v=1}^V y'_{r,m,k} \frac{\pi'_{k,q}}{\sum_{q'} \pi'_{k,q'}} \psi_{v,g}^{(\mu)} h(r, m, d)^v - \frac{\sigma_w^2}{b_g}}{\sum_{r=1}^R \sum_{m=1}^M \sum_{d=1}^D \sum_{k=1}^K y'_{r,m,k} \left(\frac{\pi'_{k,q}}{\sum_{q'} \pi'_{k,q'}} \cdot \frac{\pi'_{k,q}+1}{\sum_{q'} \pi'_{k,q'}+1} \right) [(\psi_{v,g}^{(\mu)})^2 + \psi_{v,g}^{(\sigma^2)}]}.$$

(d) 对于 $\forall q \in \{1, 2, \dots, Q\}, \forall g \in \{1, 2, \dots, Q\}$, 更新 $\phi_{q,g}^{(\sigma^2)}$:

$$\phi_{q,g}^{(\sigma^2)} = \frac{\sigma_w^2}{\sum_{r=1}^R \sum_{m=1}^M \sum_{d=1}^D \sum_{k=1}^K y'_{r,m,k} \left(\frac{\pi'_{k,q}}{\sum_{q'} \pi'_{k,q'}} \cdot \frac{\pi'_{k,q}+1}{\sum_{q'} \pi'_{k,q'}+1} \right) [(\psi_{v,g}^{(\mu)})^2 + \psi_{v,g}^{(\sigma^2)}]}.$$

(e) 对于 $\forall v \in \{1, 2, \dots, V\}, \forall g \in \{1, 2, \dots, G\}$, 更新 $\psi_{v,g}^{(\mu)}$:

$$\psi_{v,g}^{(\mu)} = \frac{\sum_{r=1}^R \sum_{m=1}^M \sum_{d=1}^D \sum_{k=1}^K \sum_{q=1}^Q y'_{r,m,k} \frac{\pi'_{k,q}}{\sum_{q'} \pi'_{k,q'}} \phi_{q,g}^{(\mu)} h(r, m, d)^v}{\sum_{r=1}^R \sum_{m=1}^M \sum_{d=1}^D \sum_{k=1}^K \sum_{q=1}^Q y'_{r,m,k} \left(\frac{\pi'_{k,q}}{\sum_{q'} \pi'_{k,q'}} \cdot \frac{\pi'_{k,q}+1}{\sum_{q'} \pi'_{k,q'}+1} \right) [(\phi_{q,g}^{(\mu)})^2 + \phi_{q,g}^{(\sigma^2)}] + \frac{\sigma_w^2}{(\sigma_\psi)_g^2}}.$$

(f) 对于 $\forall v \in \{1, 2, \dots, V\}, \forall g \in \{1, 2, \dots, G\}$, 更新 $\psi_{v,g}^{(\sigma^2)}$:

$$\psi_{v,g}^{(\sigma^2)} = \frac{\sigma_w^2}{\sum_{r=1}^R \sum_{m=1}^M \sum_{d=1}^D \sum_{k=1}^K \sum_{q=1}^Q y'_{r,m,k} \left(\frac{\pi'_{k,q}}{\sum_{q'} \pi'_{k,q'}} \cdot \frac{\pi'_{k,q}+1}{\sum_{q'} \pi'_{k,q'}+1} \right) [(\phi_{q,g}^{(\mu)})^2 + \phi_{q,g}^{(\sigma^2)}] + \frac{\sigma_w^2}{(\sigma_\psi)_g^2}}.$$

(g) 对于 $\forall k \in \{1, 2, \dots, K\}, \forall f \in \{1, 2, \dots, F\}$, 更新 $\lambda_{k,f}^{(\mu)}$:

$$\lambda_{k,f}^{(\mu)} = (\sigma_\lambda)_f \sum_{r=1}^R \delta'_{r,k} x_{r,f}.$$

(h) 对于 $\forall k \in \{1, 2, \dots, K\}, \forall f \in \{1, 2, \dots, F\}$, 更新 $\lambda_{k,f}^{(\sigma^2)}$:

$$\lambda_{k,f}^{(\sigma^2)} = (\sigma_\lambda)_f.$$

(i) 对于 $\forall r \in \{1, 2, \dots, R\}, \forall k \in \{1, 2, \dots, K\}$, 更新 $\delta'_{r,k}$:

$$\delta'_{r,k} = \frac{1}{\Psi(\sum_{j=1}^K \theta'_{r,j}) - \Psi(\theta'_{r,k}) - \sum_{f=1}^F x_{r,f} \lambda_{v,g}^{(\mu)}}.$$

其中 $\Psi(\cdot)$ 函数表示 $\Gamma(\cdot)$ 函数的二阶导数。

(j) 对于 $\forall r \in \{1, 2, \dots, R\}, \forall k \in \{1, 2, \dots, K\}$, 更新 $\theta'_{r,k}$:

$$\theta'_{r,k} = \delta'_{r,k} + \sum_{n=1}^N z'_{r,n,k} + \sum_{m=1}^M y'_{r,m,k}.$$

(k) 对于 $\forall r \in \{1, 2, \dots, R\}, \forall m \in \{1, 2, \dots, M\}, \forall k \in \{1, 2, \dots, K\}$, 更新 $y'_{r,m,k}$:

$$y'_{r,m,k} \propto \exp\left\{-\sum_{d=1}^D \sum_{q=1}^Q \sum_{g=1}^G \sum_{v=1}^V \frac{1}{2\sigma_w^2} \rho + \Psi(\theta'_{r,k}) - \Psi\left(\sum_{j=1}^K \theta'_{r,j}\right)\right\}.$$

其中 $\mathbf{y}'_{r,m}$ 是一个加和为 1 的向量, 所以其中的每个元素 $y'_{r,m,k}$ 不能直接求得, 需要进行等比例缩放。 ρ 表示为

$$\begin{aligned} \rho = & [h(r, m, d)^v]^2 - 2 \times \frac{\pi'_{k,q}}{\sum_{q'} \pi'_{k,q'}} \phi_{q,g}^{(\mu)} \psi_{v,g}^{(\mu)} h(r, m, d)^v \\ & + \left(\frac{\pi'_{k,q}}{\sum_{q'} \pi'_{k,q'}} \cdot \frac{\pi'_{k,q} + 1}{\sum_{q'} \pi'_{k,q'} + 1} \right) [(\phi_{q,g}^{(\mu)})^2 + \phi_{q,g}^{(\sigma^2)}][(\psi_{v,g}^{(\mu)})^2 + \psi_{v,g}^{(\sigma^2)}]. \end{aligned} \quad (5)$$

(l) 对于 $\forall r \in \{1, 2, \dots, R\}, \forall n \in \{1, 2, \dots, N\}, \forall k \in \{1, 2, \dots, K\}$, 更新 $z'_{r,n,k}$:

$$z'_{r,n,k} \propto \exp\left\{\sum_{i=1}^I \left\{ t_{r,n,i} \left[\Psi(\xi'_{k,i}) - \Psi\left(\sum_{j=1}^K \xi'_{k,j}\right) \right] \right\} + \Psi(\theta'_{r,k}) - \Psi\left(\sum_{j=1}^K \theta'_{r,j}\right)\right\}.$$

与 $y'_{r,m,k}$ 相似, $z'_{r,n,k}$ 也需要等比例缩放, 使 $\mathbf{z}'_{r,n}$ 成为一个加和为 1 的向量。

(m) 如果所有变分参数均已收敛, 则结束本次循环, 否则回到步骤 2a

3. 进行 EFRI 的 M 步骤循环迭代。

(a) 对于 $\forall g \in \{1, 2, \dots, G\}$, 更新 b_g :

$$b_g = \frac{\sum_{q=1}^Q \phi_{q,g}^{(\mu)}}{Q}.$$

(b) 对于 $\forall f \in \{1, 2, \dots, F\}$, 更新 $(\sigma_\lambda^2)_f$:

$$(\sigma_\lambda^2)_f = \frac{\sum_{k=1}^K ((\lambda_{k,f}^{(\mu)})^2 + \lambda_{k,f}^{(\sigma^2)})}{K}.$$

(c) 对于 $\forall v \in \{1, 2, \dots, V\}$, 更新 $(\sigma_\psi^2)_v$:

$$(\sigma_\psi^2)_v = \frac{\sum_{g=1}^G ((\psi_{v,g}^{(\mu)})^2 + \psi_{v,g}^{(\sigma^2)})}{G}.$$

(d) 更新 σ_w^2 :

$$\sigma_w^2 = \frac{\sum_{r=1}^R \sum_{m=1}^M \sum_{d=1}^D \sum_{k=1}^K \sum_{q=1}^Q \sum_{g=1}^G \sum_{v=1}^V y'_{r,m,k} \rho}{\sum_{r=1}^R \sum_{m=1}^M \sum_{d=1}^D \sum_{k=1}^K y'_{r,m,k}}.$$

其中 ρ 的定义如公式 5 所示。

(e) 对于 $\forall q \in \{1, 2, \dots, Q\}$, 更新 $(\hat{\beta}_\pi)_q$:

$$(\hat{\beta}_\pi)_q = (\beta_\pi)_q + \sum_{s=1}^Q \frac{K\Psi(\sum_{q'=1}^Q (\beta_\pi)_{q'}) - K\Psi((\beta_\pi)_q) + \sum_{k=1}^K \left(\Psi(\pi'_{k,q}) - \Psi(\sum_{j=1}^Q \xi'_{k,j}) \right)}{K\Psi'(\sum_{q'=1}^Q (\beta_\pi)_{q'}) - \delta(q, s)K\Psi'((\beta_\pi)_q)}.$$

其中 $\Psi(\cdot)$ 函数表示 $\Gamma(\cdot)$ 函数的二阶导数, $\Psi'(\cdot)$ 函数表示 $\Gamma(\cdot)$ 函数的三阶导数。当且仅当 $q = s$ 时 $\delta(q, s) = 1$ 成立, 否则 $\delta(q, s) = 0$ 。

(f) 对于 $\forall i \in \{1, 2, \dots, I\}$, 更新 $(\hat{\beta}_\xi)_i$:

$$(\hat{\beta}_\xi)_i = (\beta_\xi)_i + \sum_{s=1}^I \frac{K\Psi(\sum_{i'=1}^I (\beta_\xi)_{i'}) - K\Psi((\beta_\xi)_i) + \sum_{k=1}^K \left(\Psi(\xi'_{k,i}) - \Psi(\sum_{j=1}^I \xi'_{k,j}) \right)}{K\Psi'(\sum_{i'=1}^I (\beta_\xi)_{i'}) - \delta(i, s)K\Psi'((\beta_\xi)_i)}.$$

(g) 如果所有超参数均已收敛, 则结束本次循环, 否则回到步骤 3a

4. 如果所有参数均收敛, 则算法结束。否则回到步骤 2。

References

- [1] D. Blei, A. Ng, and M. Jordan. Latent dirichlet allocation. The Journal of Machine Learning Research, 3:993 C1022, 2003.
- [2] Blei D M , Kucukelbir A , Mcauliffe J D . Variational Inference: A Review for Statisticians[J]. Journal of the American Statistical Association, 2017:0-0.
- [3] Christopher M Bishop. Pattern Recognition and Machine Learning (Information Science and Statistics)[M]. Springer-Verlag New York, Inc. 2006.